



Vilniaus Universitetas

Vaizdų klasifikavimas naudojant konvoliucinius neuroninius tinklus

Dirbtinio intelekto pagrindai

4 užduotis

Darbą atliko:

Dovydas Martinkus

Duomenų Mokslas 4 kursas 1gr.

Vilnius, 2022

Turinys

1	Tikslas ir uždaviniai	3
2	Duomenys.....	4
3	Užduoties ataskaita	5
4	Išvados	22

1 Tikslas ir uždaviniai

Tikslas: Apmokyti konvoliucinį neuroninį tinklą vaizdams klasifikuoti, atlikti hiperparametrų ir modelio architektūros įtakos modelio rezultatams tyrimą.

Uždaviniai:

Pasirinkti duomenis - vaizdus su žinomomis klasėmis. Analizuojamų duomenų paruošimas ir aprašymas.

Pasirinkta programavimo kalba sukurti programą, kurioje įgyvendinti konvoliuciniai neuroniniai tinklai vaizdams klasifikuoti.

Atlikti tyrimą, kaip modelio rezultatai priklauso nuo hiperparametrų, modelio architektūros.

Geriausio modelio parinkimas pagal tikslumo matą, jo klasifikavimo kokybės detalus tyrimas (pagal klases).

2 Duomenys

Užduotyje naudotas CIFAR10 duomenų rinkinys. Prieiga prie duomenų per internetą:

<https://www.cs.toronto.edu/~kriz/cifar.html>.

Duomenų rinkinį sudaro 60000 nuotraukų, iš kurių kiekvienos dydis yra 32 x 32 pikselių.

Kiekvienas paveikslukas priklauso tik vienai iš 10 galimų klasių: lėktuvas, automobilis, paukštis, katė, elnias, šuo, varlė, arklys, laivas, sunkvežimis.

Duomenys padalinti testavimo aibei priskiriant 50000 stebėjimų, testavimo aibei – likusius 10000.

3 Užduoties ataskaita

Užduotis atlikta naudojant programavimo kalbą „Python“. Naudota „TensorFlow“ biblioteka, patogumo dėlei pasitelkiant „Keras“ API. Naudojant „Keras“, CIFAR10 duomenų rinkinys yra lengvai prieinamas pasitelkiant šios bibliotekos funkcijas. Nuskaičius duomenis pavaizduotas po vienas kiekvienai klasei priklausančio vaizdo pavyzdys.

```
import tensorflow as tf
from tensorflow.keras import layers
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd

# Duomenys iš https://www.cs.toronto.edu/~kriz/cifar.html
# Keras prie jų suteikia dar palengvintą prieigą
(train_images, train_labels), (test_images, test_labels) =
tf.keras.datasets.cifar10.load_data()

# Klasų pavadinimai
classes_labels =
np.char.title(["airplane", "automobile", "bird", "cat", "deer", "dog", "frog", "horse", "ship",
", "truck"])

# Kiekvienos klasės pavyzdys
fig, ax = plt.subplots(2, 5, figsize=(15, 10))
for i in range(0, 10):
    indice = np.where(train_labels == i)[0][0]
    ax[i//5, i%5].imshow(train_images[indice])
    ax[i//5, i%5].set_title(classes_labels[i])
```



1 pav. Kiekvienos klasės paveikslėlio pavyzdys

Modeliai sudaryti remiantis konvoliucinių neuroninių tinklų [pavyzdžiu TensorFlow dokumentacijoje](#). Modeliai apmokyti pasitelkiant [VU HPC sistemą](#). Naudoti 8 CPU branduoliai ir 56 GB RAM. Modeliams mokyti naudota Sparse Categorical Crossentropy nuostolių (angl. loss) funkcija. Modelių rezultatų metrika pasirinktas bendras tikslumas (angl. accuracy) ir naudota 20 epochų.

Pirmiausia palygintos kelios skirtingos neuroninio tinklo architektūros. Visuose sudarytuose modeliuose pirmiausia panaudotas Rescaling sluoksnis, skirtas duomenyse esančias RGB vertes, svyruojančias nuo 0 iki 255, normalizuoti nuo 0 iki 1. Lyginant skirtingų tinklo architektūrų rezultatus visuose modeliuose pasirinkta naudoti SGD (stochastinio gradientinio nusileidimo) optimizavimo metodą, ReLu aktyvacijos funkciją ir paketų dydį lygų 32.


Pirmajame iš lygintų modelių po Rescaling sluoksnio iš eilės naudoti Conv2D (16 filtrų), MaxPooling2D, Conv2D (32 filtrai), Flatten ir Dense sluoksniai. Konvoliucijos lango dydis pasirinktas lygus 3. Sudaryto modelio schema pavaizduota žemiau. Apmokytas modelis pasiekė 0,6 tikslumą testavimo aibėje.

Layer (type)	Output Shape	Param #
input_31 (InputLayer)	[(None, 32, 32, 3)]	0
rescaling_30 (Rescaling)	(None, 32, 32, 3)	0
conv2d_73 (Conv2D)	(None, 30, 30, 16)	448
max_pooling2d_43 (MaxPoolin	(None, 15, 15, 16)	0

g2D)


conv2d_74 (Conv2D)	(None, 13, 13, 32)	4640
flatten_30 (Flatten)	(None, 5408)	0
dense_60 (Dense)	(None, 32)	173088
dense_61 (Dense)	(None, 10)	330

=====
Total params: 178,506
Trainable params: 178,506
Non-trainable params: 0



2 pav. Pirmosios tinklo architektūros mokymo ir validacijos tikslumas pagal epochą

Antrojoje lygintoje tinklo architektūroje padidintas filtrų skaičius konvoliucijos sluoksniuose (pirmajame konvoliucijos sluoksnyje naudoti 32 filtrai, antrajame – 64), neuronų skaičius pilnai sujungtame sluoksnyje. Testavimo aibėje pasiektas tikslumas lygus 0,63.




3 pav. Antrosios tinklo architektūros mokymo ir validacijos tikslumas pagal epochą

Trečiojoje tinklo architektūroje lyginant su antrąja naudoti papildomi konvoliucijos ir surinkimo sluoksniai (taip gaunant iš eilės einančius Conv2D (32 filtrai), MaxPooling2D, Conv2D (32 filtrai), MaxPooling2D, Conv2D (64 filtrai), Flatten ir Dense sluoksnius). Apmokytas modelis testavimo aibėje pasiekė 0,67 tikslumą. Pasirinkta šią modelio architektūrą naudoti toliau tiriant hiperparametrų įtaką modelio pasiekiamiems rezultatams.

Layer (type)	Output Shape	Param #
input_1 (InputLayer)	[(None, 32, 32, 3)]	0
rescaling (Rescaling)	(None, 32, 32, 3)	0
conv2d (Conv2D)	(None, 30, 30, 32)	896
max_pooling2d (MaxPooling2D)	(None, 15, 15, 32)	0
conv2d_1 (Conv2D)	(None, 13, 13, 64)	18496
max_pooling2d_1 (MaxPooling2D)	(None, 6, 6, 64)	0
conv2d_2 (Conv2D)	(None, 4, 4, 64)	36928
flatten (Flatten)	(None, 1024)	0
dense (Dense)	(None, 64)	65600
dense_1 (Dense)	(None, 10)	650

=====
Total params: 122,570
Trainable params: 122,570

Non-trainable params: 0



4 pav. Trečiosios tinklo architektūros mokymo ir validacijos tikslumas pagal epochą

```
# modelio sudarymas
def build_model(activation):
    inputs = tf.keras.Input(shape=(32,32,3))

    # x = layers.RandomFlip("horizontal")(inputs),
    # x = layers.RandomRotation(0.1),
    x = layers.Rescaling(scale=1.0 / 255)(inputs)
    x = layers.Conv2D(32, (3, 3), activation=activation, input_shape=(32, 32, 3))(x)
    x = layers.MaxPooling2D((2, 2))(x)
    x = layers.Conv2D(64, (3, 3), activation=activation)(x)
    x = layers.MaxPooling2D((2, 2))(x)
    x = layers.Conv2D(64, (3, 3), activation=activation)(x)
    x = layers.Flatten()(x)
    x = layers.Dense(64, activation=activation)(x)
    output = layers.Dense(10)(x)

    model = tf.keras.Model(inputs, output)

    return model

# modelio mokymas
def train_model(train_images, train_labels,
                activation = "relu",
                batch_size = 32,
                optimizer="adam",
                loss=tf.keras.losses.SparseCategoricalCrossentropy(from_logits=True),
                metrics=["accuracy"],
```

```

        attempt = 1):

    model = build_model(activation)

    model.compile(optimizer=optimizer,
                  loss=loss,
                  metrics=metrics)

    tensorboard_callback = tf.keras.callbacks.TensorBoard('logs', histogram_freq=1)
    modelcheckpoint_callback = tf.keras.callbacks.ModelCheckpoint(
        filepath="modeliai/" + "hyperparameter_set_" + str(attempt) +
"/epoch_{epoch}",
        save_freq='epoch',
        save_best_only=True)

    history = model.fit(train_images, train_labels, epochs=20,
                        validation_split=0.2,
                        verbose = 2, batch_size = batch_size,
                        callbacks=[tensorboard_callback,modelcheckpoint_callback])

    return model, history

# modelio ivertinimas
def evaluate_model(model,history,test_images,test_labels,**kwargs):

    plt.plot(history.history['accuracy'], label='Mokymo duomenys')
    plt.plot(history.history['val_accuracy'], label = 'Validacijos duomenys')
    plt.xlabel('Epocha')
    plt.ylabel('Tikslumas')
    plt.legend(loc='lower right')
    plt.title(kwargs.__str__())
    plt.show()
    test_loss, test_accuracy = model.evaluate(test_images, test_labels, verbose=2)
    print("Modelio tikslumas: ", round(test_accuracy,2))

    return test_loss, test_accuracy

# mokymas ir ivertinimas
def pipeline(train_images,train_labels,
            test_images,test_labels,
            activation="relu",
            batch_size=32,
            optimizer="adam",
            loss=tf.keras.losses.SparseCategoricalCrossentropy(from_logits=True),
            metrics=["accuracy"],
            attempt = 1):

    model, history = train_model(train_images,train_labels,
                                activation,batch_size,
                                optimizer,loss,metrics,attempt)
    _, test_accuracy = evaluate_model(model,history,test_images,test_labels,
                                    activation=activation,
                                    batch_size=batch_size,
                                    optimizer=optimizer)

    return model, history, test_accuracy

```

Siekiant ištirti hiperparametrų įtaką modelio rezultatams sudarytas parametrų tinklėlis iš ReLu ir sigmoidinės aktyvacijos funkcijų, Adam ir SGD optimizavimo metodų, mokymo metu naudojamų paketų dydžių (angl. batch size) lygių 32, 64 ir 128.

```
# hiperparametrai, kurių įtaką tikrinsiu
from sklearn.model_selection import ParameterGrid

grid =
ParameterGrid({"activation":["relu","sigmoid"],"batch_size":[32,64,128],"optimizer":["sgd","adam"]})

results = pd.DataFrame(list(grid))

test_accuracies = []
models = []
histories = []
```

Naudojant kiekvieną hiperparametrų rinkinį modelis apmokytas naudojant mokymo duomenų aibę. Mokymo metu 0,2 mokymo aibės naudota validacijai. Kiekvienos epochos metu gauti mokymo ir validacijos tikslumai pavaizduoti grafiškai. Iš grafikų galima matyti stipri mokymo epochos įtaka: daugeliu atveju didėjant epochai stipriai gerėja rezultatai vertinimui naudojant tiek mokymo, tiek validacijos aibes.


Kiekvienam modeliui taip pat išsaugoti tikslumas ir paklaida gauti su testavimo duomenimis.

Žemiau esantis kodas kartotas su $i=0, 1, \dots, 11$:


```
i = 0

model, history, accuracy =
pipeline(train_images,train_labels,test_images,test_labels,
        **grid[i],attempt = i)


test_accuracies.append(accuracy)
models.append(model)
histories.append(history)
```




5 pav. Mokymo ir validacijos tikslumas pagal epochą (1 hiperparametrų rinkinys)




6 pav. Mokymo ir validacijos tikslumas pagal epochą (2 hiperparametrų rinkinys)




7 pav. Mokymo ir validacijos tikslumas pagal epochą (3 hiperparametrų rinkinys)




8 pav. Mokymo ir validacijos tikslumas pagal epochą (4 hiperparametrų rinkinys)




9 pav. Mokymo ir validacijos tikslumas pagal epochą (5 hiperparametrų rinkinys)




10 pav. Mokymo ir validacijos tikslumas pagal epochą (6 hiperparametrų rinkinys)




11 pav. Mokymo ir validacijos tikslumas pagal epochą (7 hiperparametrų rinkinys)




12 pav. Mokymo ir validacijos tikslumas pagal epochą (8 hiperparametrų rinkinys)




13 pav. Mokymo ir validacijos tikslumas pagal epochą (9 hiperparametrų rinkinys)



14 pav. Mokymo ir validacijos tikslumas pagal epochą (10 hiperparametrų rinkinys)



15 pav. Mokymo ir validacijos tikslumas pagal epochą (11 hiperparametrų rinkinys)



16 pav. Mokymo ir validacijos tikslumas pagal epochą (12 hiperparametrų rinkinys)

```
results["test accuracies"] = np.round_(test accuracies, 2)
results
```

Visų tikrintų modelių rezultatai pateikti lentelėje (1 lentelė). Ja naudojantis galime matyti, kad geriausi rezultatai gauti naudojant modelį su ReLu aktyvacijos funkcija, imant 128 paketo dydį ir Adam optimizavimo metodą. Šis modelis bus naudojamas tolimesniame tyrime. Apskritai matome, kad naudojant ReLu aktyvacijos funkcija pasiekiami geresni rezultatai negu sigmoidinė. Panašus rezultatų pagerėjimas matomas ir naudojant Adam optimizavimo funkciją vietoje SGD. Tuo tarpu paketo dydžio įtaka nebuvo tokia ryški kaip kitų dviejų parametrų.

1 lentelė Testavimo aibės rezultatai kiekvienam hiperparametrų rinkiniui

Aktyvacijos funkcija	Paketo dydis	Optimizavimo metodas	Testavimo aibės bendras tikslumas	Nuostolių funkcijos reikšmė
relu	32	sgd	0,67	0,960
relu	32	adam	0,68	1,355
relu	64	sgd	0,63	1,070
relu	64	adam	0,68	1,149
relu	128	sgd	0,52	1,335
relu	128	adam	0,70	0,937
sigmoid	32	sgd	0,11	2,303
sigmoid	32	adam	0,60	1,138
sigmoid	64	sgd	0,10	2,304
sigmoid	64	adam	0,57	1,057
sigmoid	128	sgd	0,10	2,303
sigmoid	128	adam	0,54	1,270

```
model = models[np.argmax(test_accuracies)]
# Geriausias sudarytas modelis išsaugomas
model.save("modeliai/geriausias")
best_model = tf.keras.models.load_model("modeliai/geriausias")
```

```
from sklearn.metrics import accuracy_score, confusion_matrix
```

```
y_pred = best_model.predict(test_images)
y_pred = [np.argmax(i) for i in y_pred]
confusion_matrix = confusion_matrix(test_labels, y_pred)
print(confusion_matrix)
```

```
test_accuracy = accuracy_score(test_labels, y_pred)
print("Geriausio modelio tikslumas: ", round(test_accuracy,2))
```

Naudojant maišos matricą (angl. confusion matrix) pavaizduoti geriausio modelio rezultatai testavimo aibėje (2 lentelė):

2 lentelė Maišos matrica testavimo aibės duomenims naudojant geriausią modelį

Prognuzuota \ Tikra	0	1	2	3	4	5	6	7	8	9
0	746	20	55	16	23	4	11	9	84	32
1	29	826	7	8	4	1	7	3	35	80
2	78	6	580	66	122	54	50	16	17	11
3	21	10	82	543	90	125	49	39	24	17
4	21	8	56	73	693	38	42	56	10	3
5	19	7	68	209	52	569	15	36	15	10
6	11	4	56	92	43	28	740	7	12	7
7	21	4	52	49	78	56	8	713	7	12
8	71	35	13	17	9	4	3	2	822	24
9	43	86	6	17	4	8	9	15	26	786

Naudojant geriausią modelį ir testavimo aibės duomenis pateiktos rezultatų kokybės metrikos kiekvienai klasei atskirai (3 lentelė). Matome, kad modeliui blogiau sekėsi klasifikuoti kates ir paukščius. Pasinaudoję maišos matrica matome, kad katės dažnai sumaišytos su šunimis, tuo tarpu paukščiai – su elniais. Geriausiai modeliui sekėsi klasifikuoti automobilius ir sunkvežimius.

```
from sklearn.metrics import classification_report

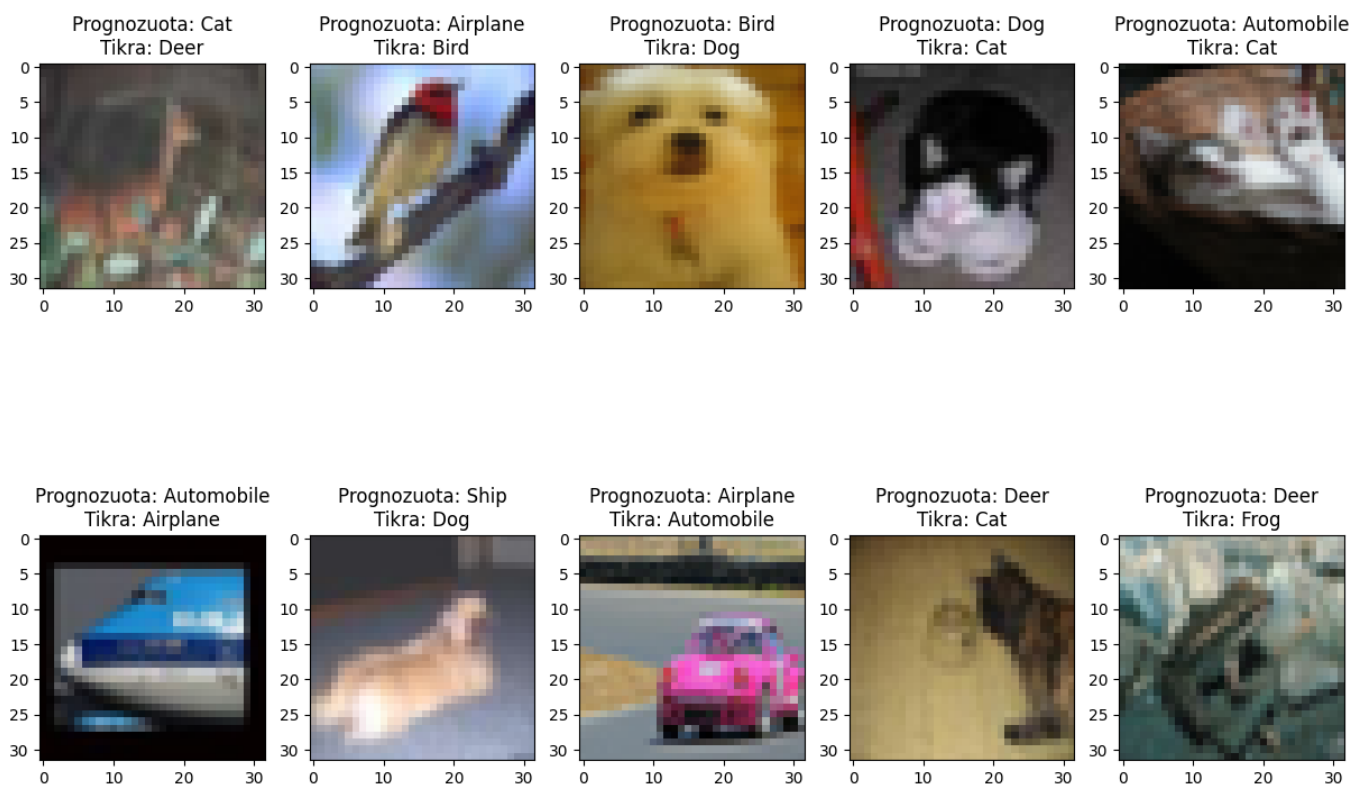
# greitas būdas pažiūrėti kaip gerai klasifikuojama kiekviena klasė
results_frame =
pd.DataFrame(classification_report(test_labels,y_pred,output_dict=True))
results_frame.columns =
np.concatenate((classes_labels,results_frame.columns[10:].values))
results_frame
```

3 lentelė Geriausio modelio rezultatai testavimo aibėje kiekvienai klasei atskirai

	Teigiamas prognostinis dydis (angl. precision)	Jautrumas (angl. sensitivity)	F1 dydis
Lėktuvas	0,7	0,75	0,72
Automobilis	0,82	0,83	0,82
Paukštis	0,59	0,58	0,59
Katė	0,5	0,54	0,52
Elnias	0,62	0,69	0,65
Šuo	0,64	0,57	0,6
Varlė	0,79	0,74	0,77
Arklis	0,8	0,71	0,75
Laivas	0,78	0,82	0,8
Sunkvežimis	0,8	0,79	0,79

Pasirinkta pavaizduoti pavyzdžius vaizdų, kuriuos geriausias modelis klasifikavo klaidingai (17 pav.):

```
# Kelių neteisingų prognozių pavyzdžiai
wrong_indices = np.random.choice(np.where(y_pred != test_labels[:,0])[0],10)
fig, ax = plt.subplots(2,5,figsize=(15, 10))
for i in range(0,10):
    indice = wrong_indices[i]
    ax[i//5,i%5].imshow(test_images[indice])
    ax[i//5,i%5].set_title("Prognozuota: " + classes_labels[y_pred[indice]] +
        "\n" +
        "Tikra: " + classes_labels[test_labels[indice][0]])
```



17 pav. Neteisingai klasifikuotų stebėjimų pavyzdžiai

Lentelėje pavaizduotas dar keletas modelio prognozuotų ir tikrų klasių pavyzdžių (4 lentelė):

```
print("Keli atsitiktiniai stebėjimai iš testavimo aibės:")
tikra = []
prognozuota = []
teisinga = []
indices = np.random.choice(np.where(np.array(y_pred) == np.array(y_pred))[0],30)
for i in indices:
    teisinga.append(y_pred[i] == test_labels[i][0]),
    prognozuota.append(classes_labels[y_pred[i]]),
    tikra.append(classes_labels[test_labels[i][0]])
```

```
pd.DataFrame({"Teisinga":teisinga,"Tikra":tikra,"Prognozuota":prognoz
```

4 lentelė Klasifikavimo testavimo aibėje naudojant geriausių modelių pavyzdžiai

Teisinga	Tikra klasė	Prognozuota klasė
Taip	Dog	Dog
Taip	Horse	Horse
Taip	Cat	Cat
Taip	Ship	Ship
Ne	Cat	Bird
Taip	Ship	Ship
Taip	Truck	Truck
Taip	Deer	Deer
Taip	Truck	Truck
Taip	Ship	Ship
Ne	Cat	Dog
Taip	Deer	Deer
Taip	Ship	Ship
Ne	Deer	Bird
Taip	Dog	Dog
Ne	Deer	Frog
Taip	Deer	Deer
Ne	Ship	Automobile
Taip	Airplane	Airplane
Ne	Automobile	Truck
Taip	Dog	Dog
Taip	Horse	Horse
Taip	Frog	Frog
Taip	Ship	Ship
Taip	Dog	Dog
Ne	Dog	Cat
Taip	Truck	Truck
Taip	Deer	Deer
Taip	Horse	Horse
Taip	Bird	Bird

4 Išvados

Atlikus skirtingų neuroninių tinklų architektūrų tyrimą, geriausi rezultatai pasiekti naudojant sudėtingiausią architektūrą (kurią sudaro iš eilės einantys Rescaling, Conv2D (32 filtrai), MaxPooling2D, Conv2D (32 filtrai), MaxPooling2D, Conv2D (64 filtrai), Flatten ir Dense sluoksniai), lyginant su modeliais, naudojančiais mažesnę konvoliucijos ir surinkimo sluoksnių kiekį, mažesnę filtrų skaičių konvoliucijos sluoksniuose. Sudėtingesnės neuroninio tinklo architektūros tirtos nebuvo.

Mokymo metu pastebėta stipri mokymo epochos įtaka – didėjant epochai daugeliu atveju gautas ryškus klasifikavimo rezultatų pagerėjimas tiek mokymo, tiek validacijos aibėse.

Didžiausia įtaką tarp hiperparametrų modelio pasiekiamiems rezultatams turėjo aktyvacijos funkcija: Naudojant ReLu gauti stipriai geresni rezultatai negu pasitelkiant sigmoidinę aktyvacijos funkciją. Taip pat svarbi naudojamo optimizacijos metodo įtaka: naudojant Adam gauti geresni rezultatai negu su SGD. Paketo dydžio reikšmės įtaka gautiems rezultatams daug mažesnė.

Geriausieji rezultatai gauti naudojant modelį su ReLu aktyvacijos funkcija, imant 128 paketo dydį ir Adam optimizavimo metodą.

Geriausias modelis prasčiausiai atpažino kates nuo šunų, taip pat ir paukščius nuo elnių. Geriausiai modeliui sekėsi atpažinti automobilius ir sunkvežimius.

Bendri geriausio modelio pasiekti rezultatai nėra itin geri (didžiausias tikslumas testavimo aibėje – 0,7). Galima šio rezultato priežastis – stipriai sumažinta naudotų paveikslėlių raiška.